Praktikum strojnega učenja

1. naloga - Modeliranje 1-D porazdelitev: Razpadi Higgsovega bozona

Žan Butala

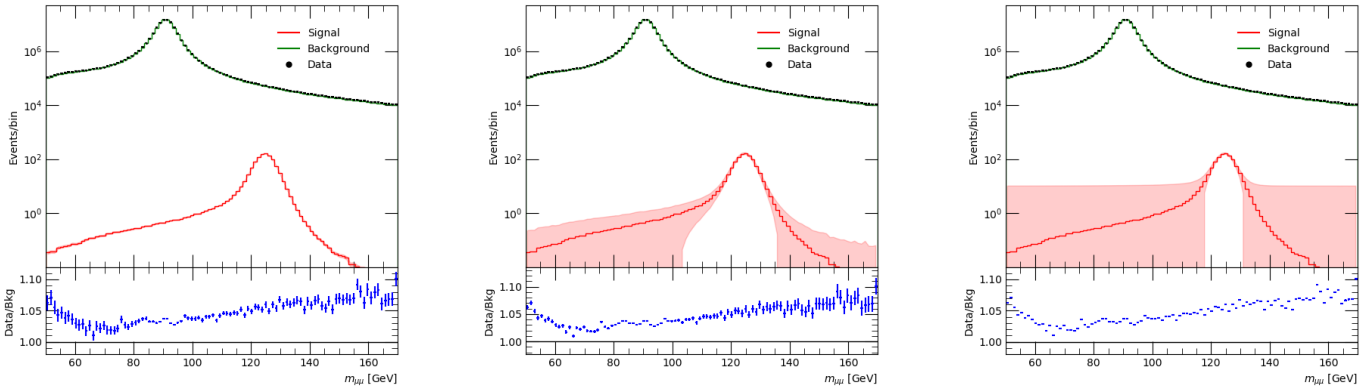
18. oktober 2023

Univerza v Ljubljani
Fakulteta za matematiko in fiziko

1 Fitanje funkcij

Higgsov bozon razpada v več razpadnih produktov, $\bar{b}b$, **WW**, **gg**, $\tau\tau$, **ZZ**, $\gamma\gamma$ in $\mu\mu$. V tej nalogi nas je zanimal slednji proces. Iz meritev in simuliranih podatkov smo poskušali izluščiti signal razpada $H \to \gamma\gamma$ iz bistveno večje količine ozadaja. Pri tem smo preizkusili več različnih metod modeliranja in glajenja porazdelitev.

Na začetku si za občutek oglejmo s čim se sploh spopadamo. Slika 1 prikazuje histograme ozadja in željenega signala. Prosojen pas ponazarja velikosti napak, ki so upoštevane napačno. Ker vemo, da se Higgsov delec nahaja



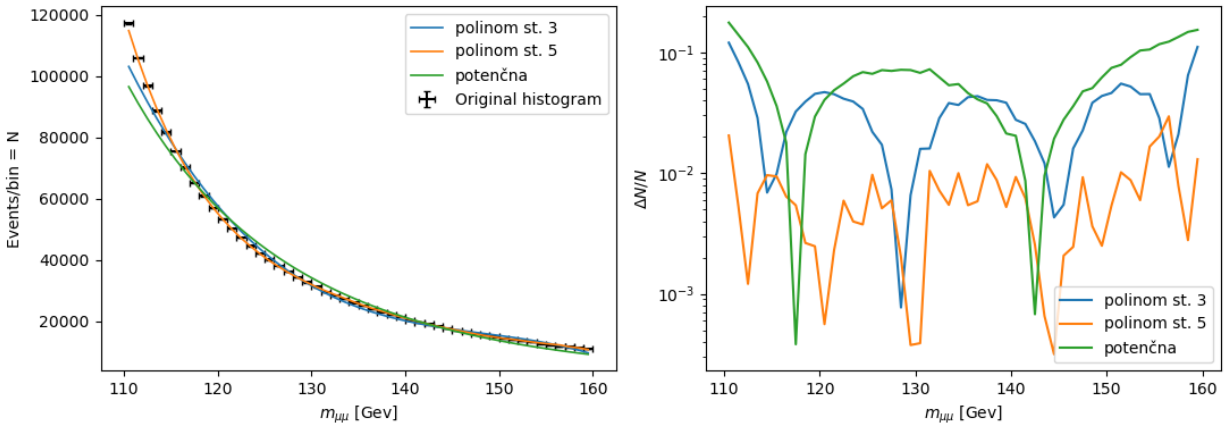
(a) Prave napake (b) Poissonske napake (c) konst. napake

Slika 1: Vpliv upoštevanja napak

v okolici 125GeV, si življenje olajšamo, če se osredotočimo na njegovo okolico. Histogram ozadja na tem območju lahko približno opišemo z enostavnejšimi krivuljami, kot so polinomi, potenčne, eksponentne funkcije ali pa kakšno bolj sofisticirano. V prvem delu sem si ogledal prileganje naslednjih družin funkcij:

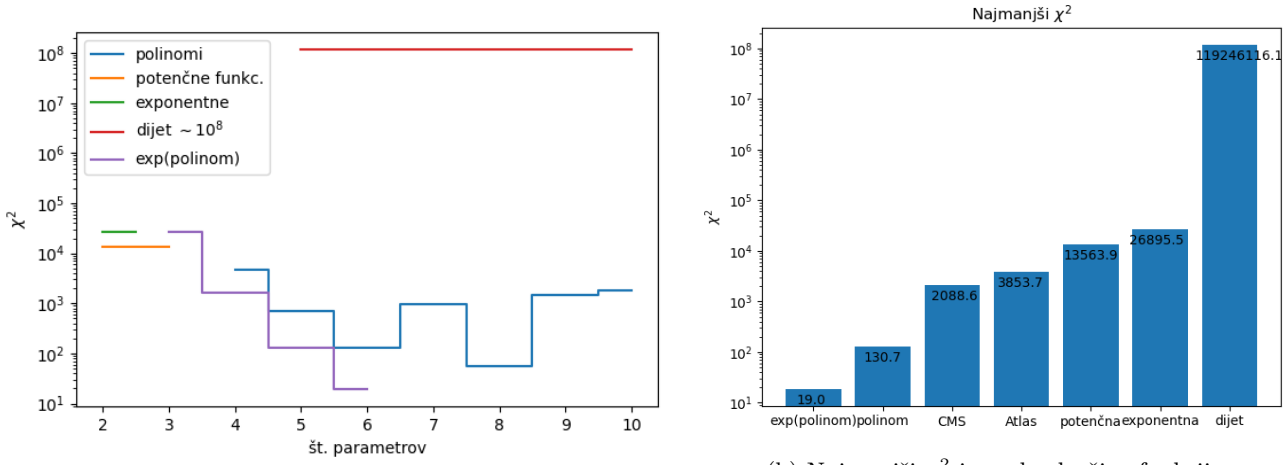
$$\begin{aligned} f(m) &= a_1 + a_2 m + a_3 m^2 + \ldots, \\ f(m) &= a_1 m^{b1} + a_2 m^{b_2} + \ldots, \\ f(m) &= a_1 e^{-b_1 m} + a_2 e^{-b_2 m} + a_3 e^{-b_3 m} + \ldots, \\ f(m) &= a(1-m^c)^d m^{b_1 + b_2 ln(m) + b_3 ln(m^2) + \ldots}, \\ f(m) &= a e^{b1 m + b_2 m^2 + \ldots}. \end{aligned} \tag{1}$$

Tri najbolj preproste prikazuje slika 2.



Slika 2: Ujemanje preprostih prilagajanih funkcij (levo) in relativna odstopanja (desno).

Kakovost ujemanja lahko zapišemo tudi s skalarno količino χ^2. To sem pogledal za vsako družino krivulj v odvisnosti od števila parametrov (slika 3) - z večjim številom parametrov pričakujemo boljše ujemanje. Kot vemo že iz drugih predmetov obstaja optimum, ki se na grafu $\chi^2(\#parametrov)$ navadno odraža kot prelom strmine, desno od njega pa je "overfitting". V našem primeru se to najlepše kaže pri polinomih z optimumom pri $n = 6$. Če za vsako družino krivulj poberemo optimalni χ^2 in ga dodamo v histogram, lahko na nek način primerjamo ustreznost krivulj med sabo. Pri nekaterih krivuljah `curve_fit` ni našel optimalnih parametrov že pri $n = 4$, zato sem tam vzel najmanjšo doseženo vrednost. Iz desnega histograma vidimo, da se podatkom na intervalu [110, 160] najboljše prilega eksponent polinomov s šestimi parametri, pri čemer se zavedamo, da imata funkciji s fizikalnim ozadjem manjše število parametrov.

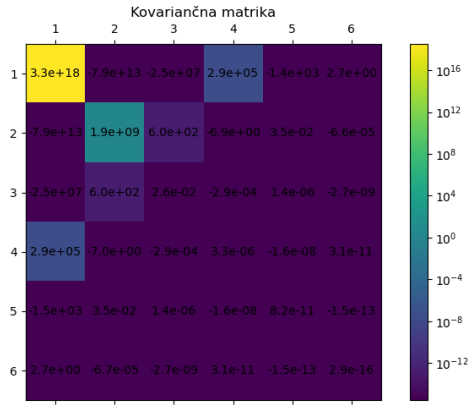


(a) χ^2.

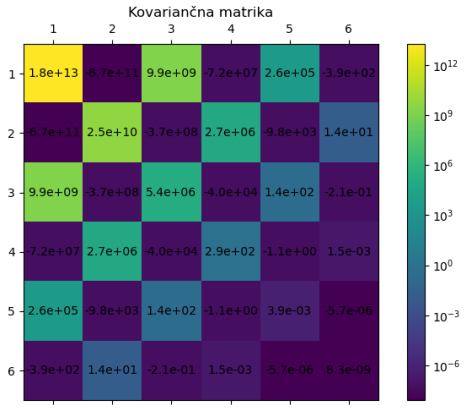
(b) Najmanjši χ^2 iz vsake družine funkcij.

Slika 3: Ujemanje fitanih funkcij.

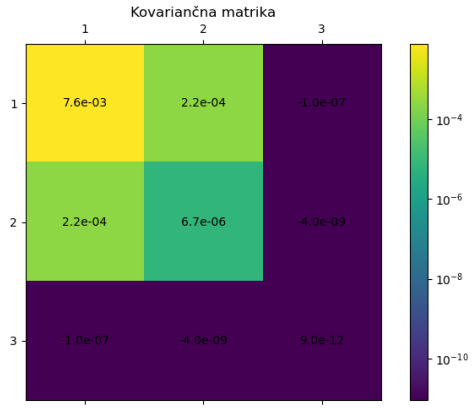
Spodobi se upoštevati še kovariance optimalnih parametrov. Slika 4 namiguje, da samo χ^2 ni dobra mera za kakovost prileganja. Če pogledamo variance parametrov, vidimo, da je največja pri CMS reda velikosti 10^{-3}, pri ostalih (fizikalno neutemeljenih) pa so tudi 15 redov večje.



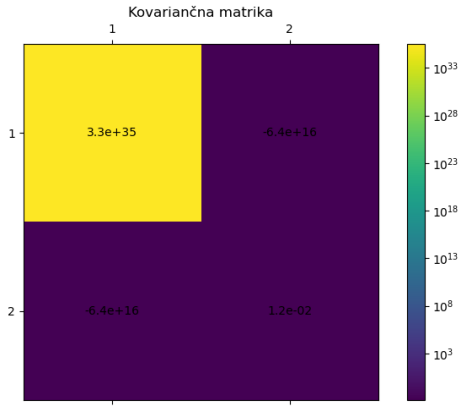
(a) exp(polinom).



(b) Polinom.



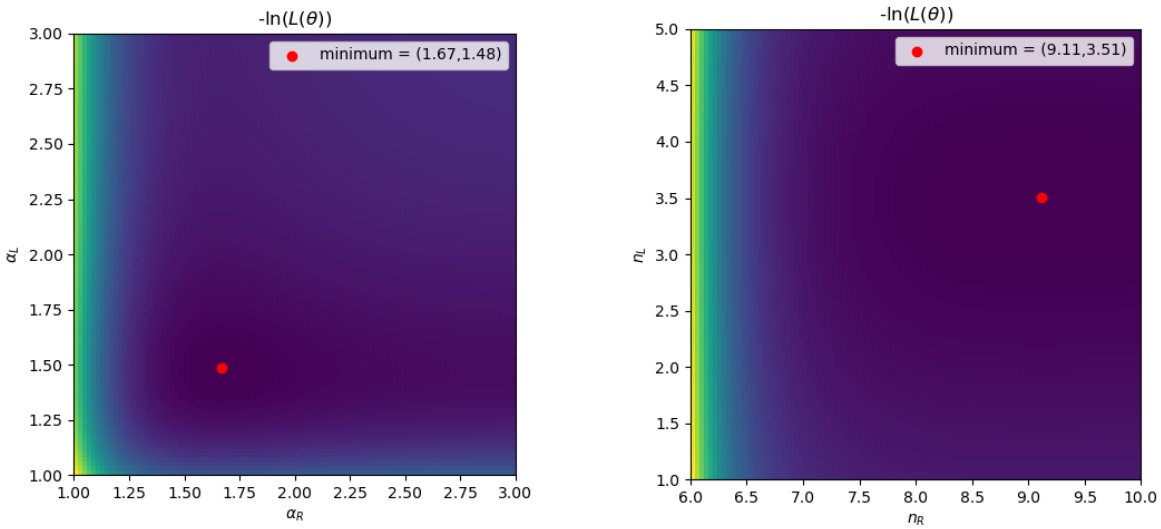
(c) CMS.



(d) Potenčna.

Slika 4: Kovariance fitanih parametrov. Pri Atlasu samo 1 parameter; $\sigma^2 = 1.2 \cdot 10^{24}$, pri *dijet* pa $\mathrm{cov}_{ij} = \infty$.

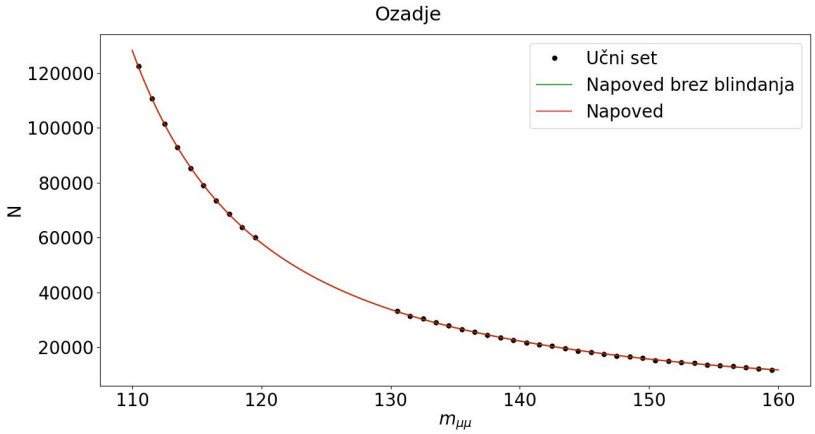
Obliko simuliranega signala lahko opišemo s funkcijo oblike *Crystal Ball*, ki je kombinacija osrednje Gaussovske porazdelitve in debelejših potenčnih repov. Ker funkcija vsebuje preveč parametrov, ki so precej korelirani, lahko zadovoljivo prileganje najdemo s pregledom po parih parametrov. Minimuma za dva para parametrov sta prikazani na sliki 5. Če vstrajamo s `curve_fit` metodo, dobimo $\alpha_L = 1.47$, $\alpha_R = 1.67$, $n_L = 3.75$, $n_R = 9.65$, ..., kar se ujema z prejšnjim postopkom.



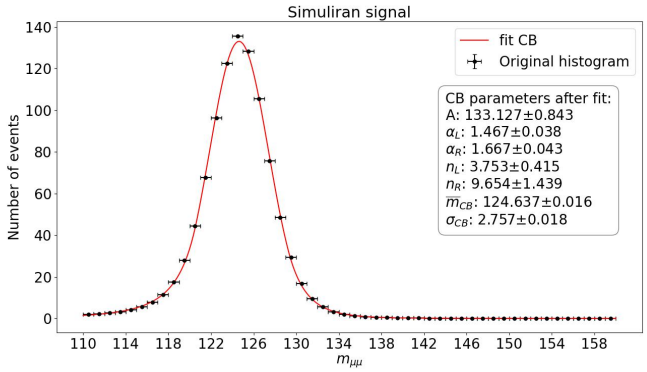
(a) α_L, α_R. (b) n_L, n_R.

Slika 5: Iskanje optimalnih parametrov za CB.

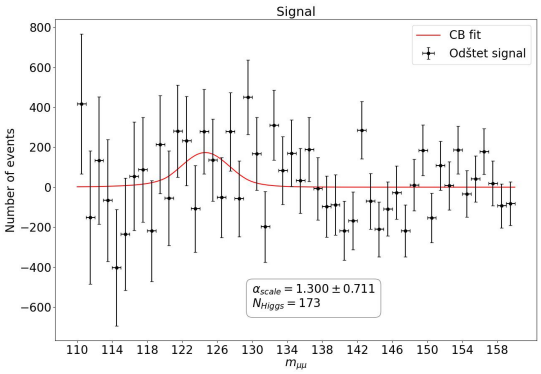
Ideja je, da CB prlagodimo na simulirane podatke, nato pa na razliko podatkov in fita ozadja prilagajamo α·CB, kjer je α prost parameter. Preden pa odštejemo fit od podatkov, oziroma sploh izvajamo fitanje ozadja, je smiselno izločiti interval na katerem pričakujemo vrh. Dano krivuljo torej prilagajamo na podatke brez tistih, ležijo na intervalu [120,130] in jo odštejemo od podatkov. Rezultat je prikazan na sliki 7.



Slika 6: Razlika med napovedmi z izločanjem območja signala in brez. Odstopanja so reda velikosti 10^3. Slika je iz GPR z Mantelovim jedrom.



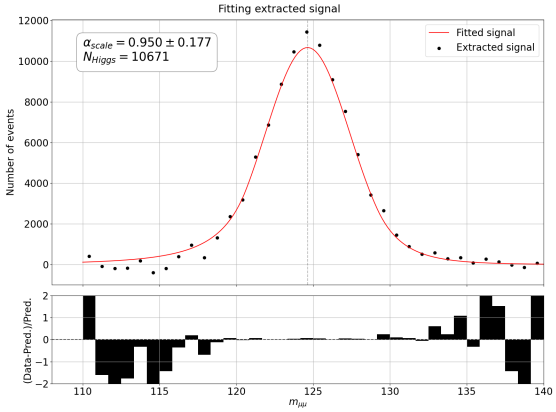
(a) Simuliran signal.



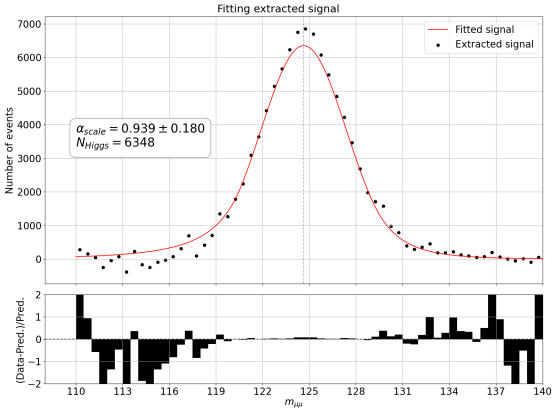
(b) Podatki minus ozadje z Atlas.

Slika 7: Fitanje Crystal Ball funkcije na signal.

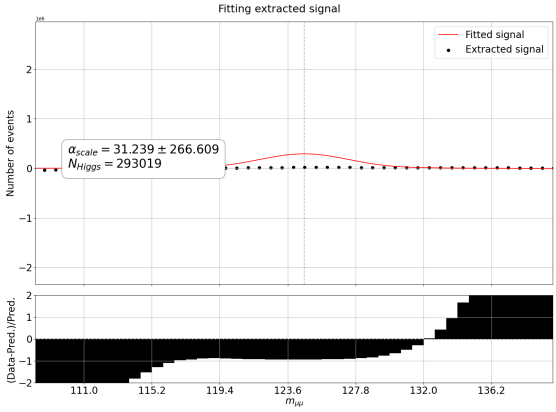
V nadaljevanju sem pogledal še vpiv širine intervala in števila bin-ov na končni rezultat, pri čemer sem signal umetno napihnil. Iz slike 8 je razvidno, da povečanje števila bin-ov poslabša fit - res, s tem sicer dobimo več točk za fitanje, vendar se bin_values zmanjšajo ter se poveča napaka. Še hitreje pokvarimo sliko s povečevanjem intervala. Če spremenimo [110,160] → [90,180] dobimo popolnoma neuporaben rezultat (slika 8c). Pri 8d sem začetni signal pomnožil se z večjim faktorjem, kar seveda izboljša končni rezultat.



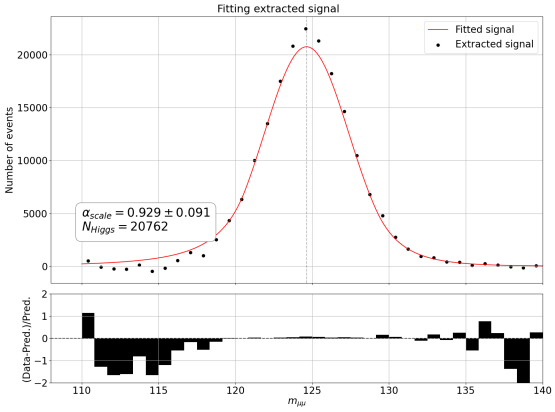
(a) 60 bins, x100.



(b) 100 bins, x100.



(c) 100 bins, x100, večji interval.

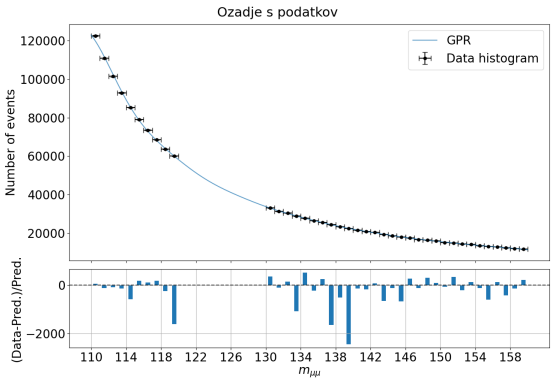


(d) 60 bins, x200.

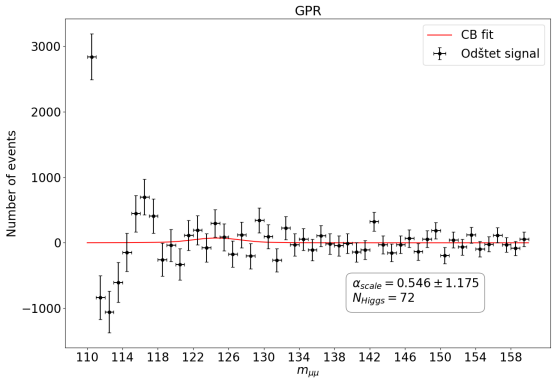
Slika 8: Fitanje Crystal Ball funkcije na napihnjen signal.

2 Gaussian regression process

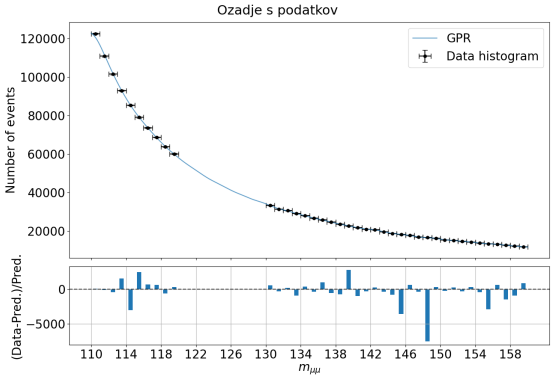
Na koncu sem vajo ponovil še z metodo GPR, pri čemer sem uporabil različna jedra. Iz slike 9 vidimo predvsem to, da rezultati niso dobri. Za nekoliko manj slabega se je izkazal kernel Mantel, čeprav ima večji razpon relativnih odstopanj. Na koncu sem poskusil še metodo Kernel Ridge Regression, vendar sem se nekje zapletel, predvidevam, da pri skaliranju podatkov. Poskus je prikazan na sliki 10, v prvem delu je delovalo obetavno, na koncu pa mi je zmanjkalo časa, da bi pridelal smiselen rezultat.



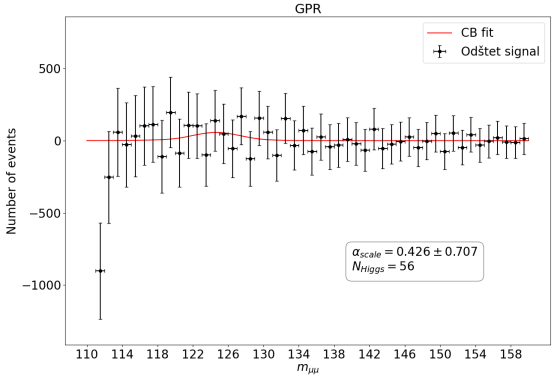
(a) RBF kernel.



(b) Podatki - ozadje(RBF).

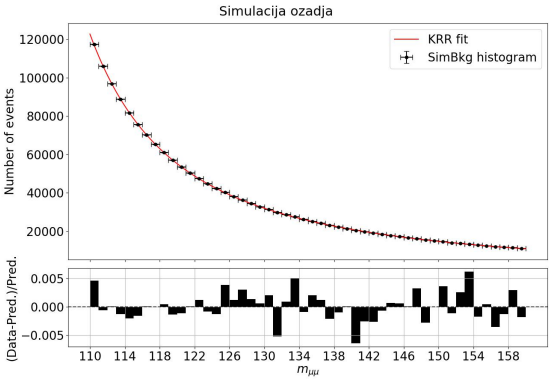


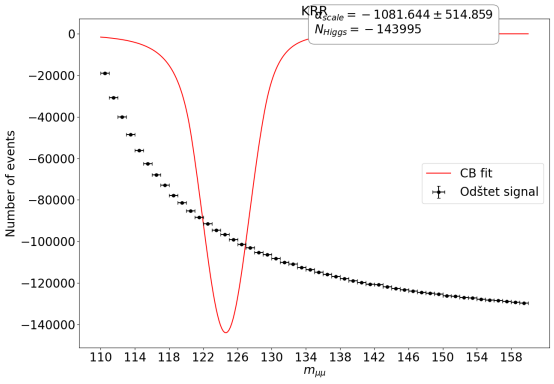
(c) Mantel kernel.



(d) Podatki - ozadje(Mantel).

Slika 9: Rezultati z GPR.





Slika 10: Poskus s Kernel Ridge Regression.