Praktikum strojnega učenja

2. naloga: Klasifikacija zvezdnih spektrov

Žan Butala

2. november 2023

Univerza v Ljubljani
Fakulteta za matematiko in fiziko

1 Zvez(d)ni spektri

Pri tej nalogi obravnavamo zvezdne spektre, ki so bili posneti v projektu GALAH (Galactic Arhcaeology with Hermes). Spektrometer Hermes omogoča, da hkrati izmerimo svetlobni spekter več kot 400 nebesnih teles. Namen opazovanja GALAH je bil določiti časovni razvoj kemijske strukture naše galaksije. Podobno, kot pri zemeljski arheologiji lahko s preučevanjem zvezd dobimo podatke o njihovi preteklosti. Na sestavo elementov v zvezdi vplivajo kemijske razmere okolice ob njenem nastanku. Starejše zvezde imajo manjši delež kovin kot mlajše, za zvezdi s podobno sestavo pa lahko sklepamo, da sta nastali v bližnji okolici.

Pri tej nalogi bomo obravnavali naslednje skupine zvezdnih spektrov:

- MAB - zvezde z molekulskimi absorpcijskimi črtami

  zadnje je značila ne-široka vodikova absorpcijska črta in druge pri 6600 ter 6620Å.

- BIN - dvojne zvezde

  Manjše absorbcijske črte pri 6610, 6630, 6640Å.

- TRI - trojne zvezde

  Trojne absorpcijske črte pri 6645, 6665Å

- HFR - vroče, hitro vrteče se zvezde

  Razširjena vodikova črta v obliki črke U.

- HAE - zvezde s Hα emisijo

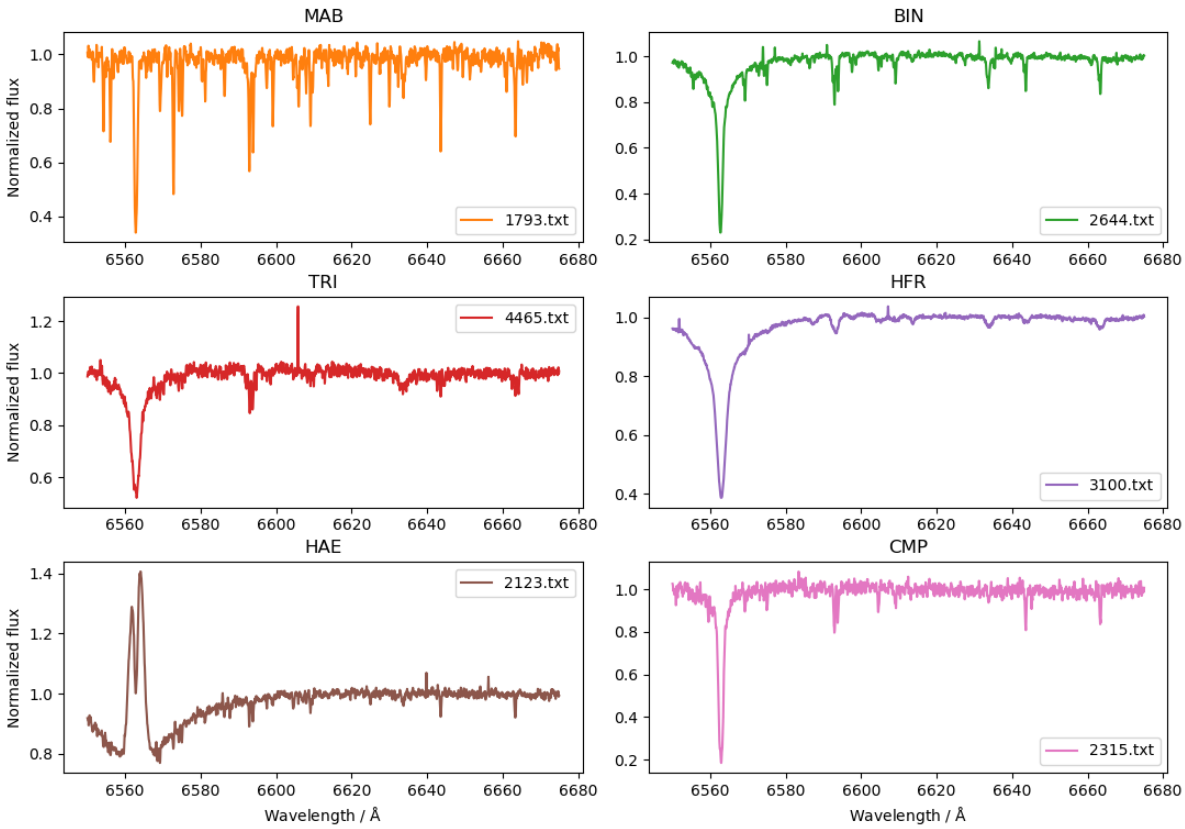
  Izstopajoča emisijska črta Hα.

- CMP - hladne zvezde z malo kovinami

  Ozka absorpcijska črta $H\alpha$.

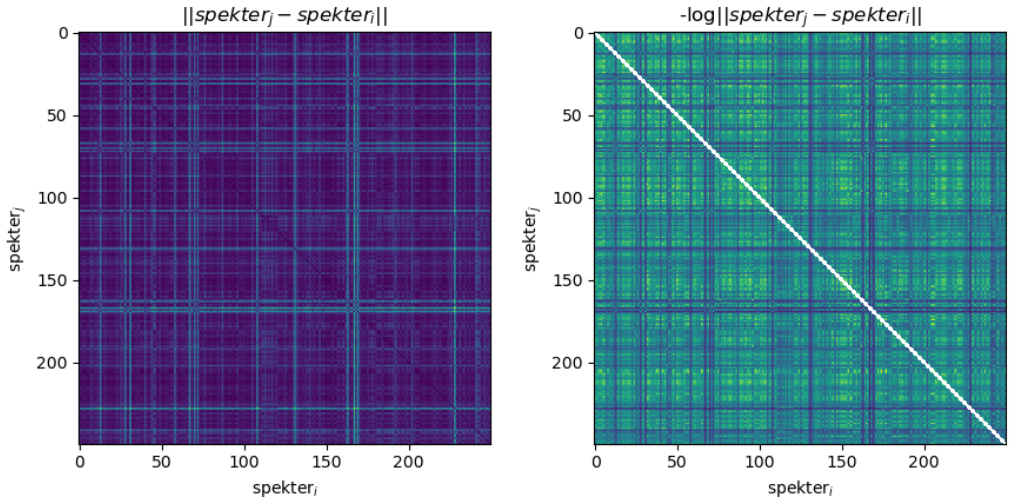
- DIB - vroče zvezde z medzvezdnimi črtami

  Absorpcijska črta pri 6610Å.



Slika 1: Nekateri reprezentativni zvezdni spektri iz nabora učnih podatkov.

Ker so spektri normirani in odrezani na isto okno frekvenc, se splača pogledati tudi razliko med njimi. To lahko naredimo na več načinov, najbolj preprosta je kar razlika med njimi; torej če seštevamo absolutne razlike po zaporednih vrednostih (diskretna verzija ploščine med krivuljama). Sklepamo, da bosta podobna dva spektra rezultirala v majhno razliko. Ker iščemo gruče s podobnimi spektri, je smiselno rezultat logaritmirat in množit z minus ena. Najbolj podobni spektri (prvih 250) so na sliki 2 desno prikazani s svetlo rumeno izven diagonale. Naslednja možnost za metriko, ki kliče po implementaciji je χ^2. Legitimnost tega pristopa bomo lahko tudi ovrednotili po primerjavi s t-SNE.



Slika 2: Primerjava spektrov s pomočjo integrala absolutnega odstopanja med pari.

2 PCA

Principal Component Analysis je metoda, s katero zmanjšamo dimenzionalnost točk. Algoritem je matematično preprost in se prevede na problem iskanja lastnih vektorjev. n vektorjev dimenzije p zložimo v matriko $X \in \mathbb{R}^{n \times p}$, ter izračunamo odstopanja od povprečja za vsak stolpec:

$$u_j = \frac{1}{n} \sum_i X_{ij}. \tag{1}$$

Matriko premaknemo za povprečje

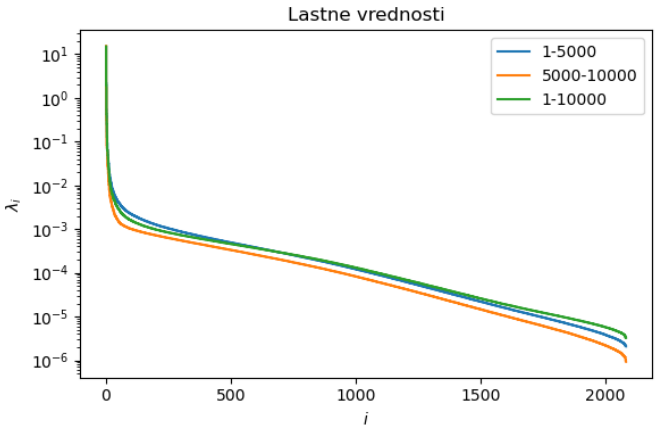
$$B = X - \mathbf{h}\mathbf{u}^T, \tag{2}$$

kjer je $\mathbf{h}$ vektor enic. Nato izračunamo kovariančno matriko

$$C = \frac{1}{n-1} B^T B \tag{3}$$

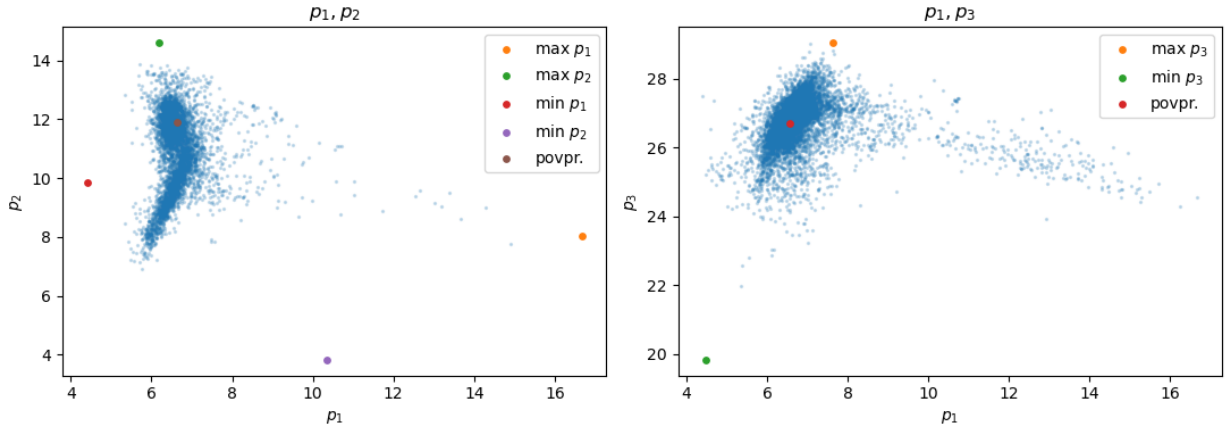
ter poiščemo lastne vrednosti λ_k in pripadajoče lastne vektorje $\mathbf{v}_k$, ki jih zložimo v matriko W. Začetne podatke projiciramo na bazo lastnih vektorjev

$$T = XW. \tag{4}$$



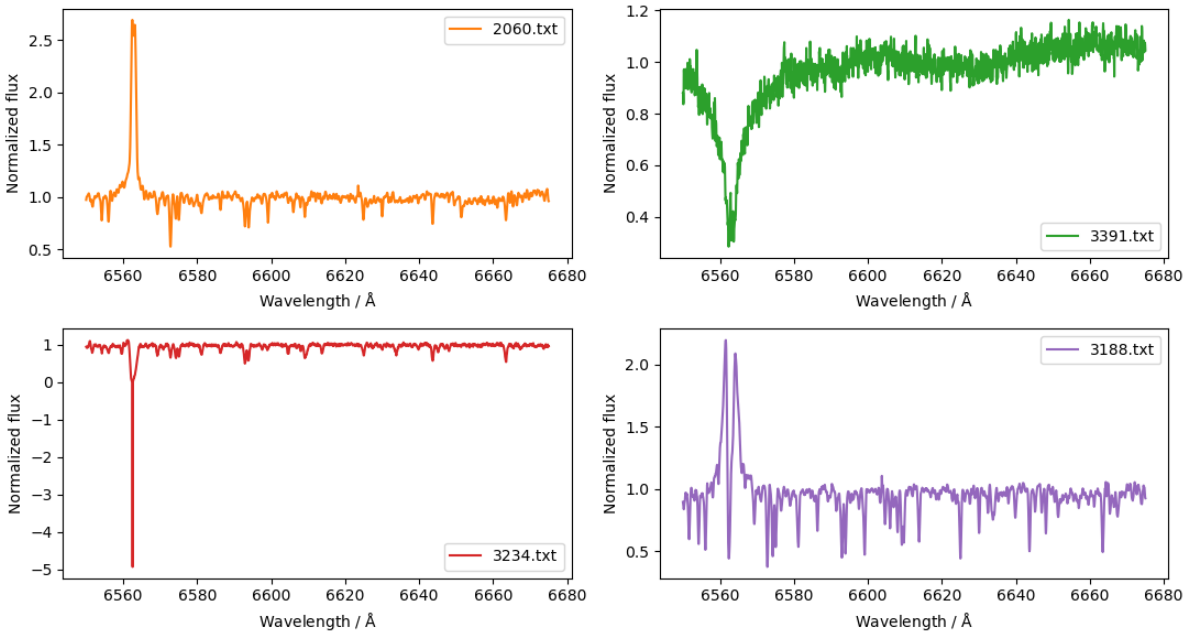
Slika 3: Lastne vrednosti matrike C, urejene po velikosti.

Po vrsti urejene lastne vrednosti so prikazane na sliki 3. Opazimo, da že v prvih nekaj velikost pade za skoraj 4 velikostne rede. Če lastne vrednosti predstavljajo energijo vidimo, da 90% zajamemo že s tremi lastnimi vrednostmi. Na sliki 4 je prikazan rezultat redukcije PCA na prve tri lastne vektorje. Leva ustreza projekciji na prvi dve prostostni stopnji, desna pa na prvo in tretjo. Analogno lahko projiciramo na poljuben par, tudi trojico ali več dimenzionalne podprostore. Za vsako od teh prostostnih stopenj sta na sliki označeni točki, ki zavzemata minimalno in maksimalno vrednost.

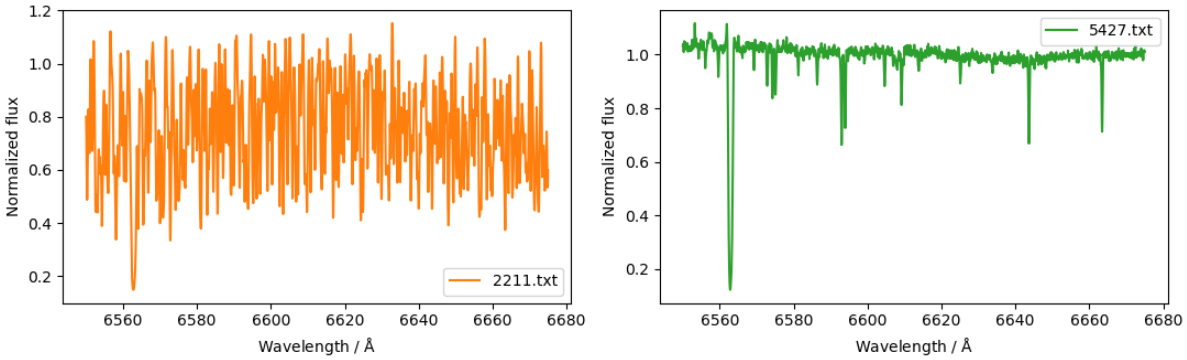


Slika 4: Redukcija na dve spremenljivki: leva slika pripada projekciji na prva dva lastna vektorja, desna pa na prvega in tretjega.

Če si ogledamo spektre, ki ustrezajo tem skrajnim točkam vidimo, da se popolnoma razlikujejo (sliki 5 in 6). Največja skrajna lega za spremenljivko p_1 (oranžen spekter na sliki 5) predstavlja tipičen HAE spekter, za p_2 (zelen spekter na sliki 5) pa HRF. Če nadaljujemo z najmanjšimi skrajnimi legami in preostalimi projekcijskimi dimenzijami (slika 6), najdemo tudi popolnoma zašumljene spektre, spektralne oblike pa se začnejo slej kot prej ponavljati.

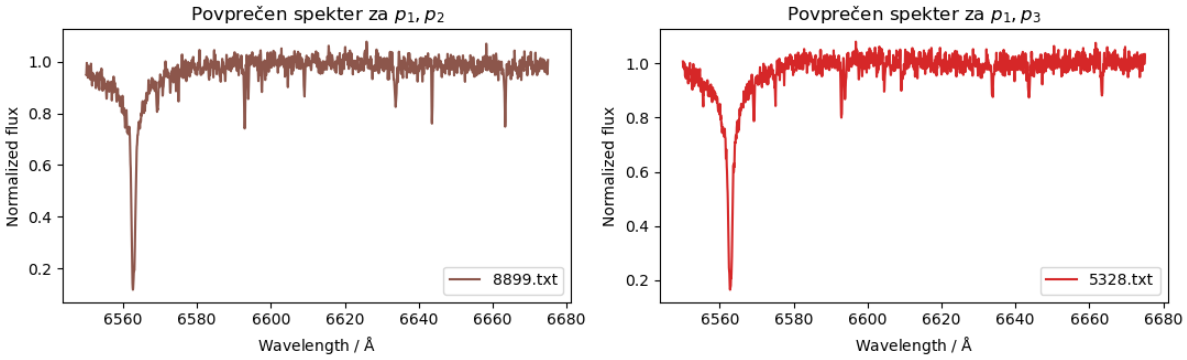


Slika 5: Spektri skrajnih točk iz projekcije na par parametrov p_1, p_2. Barve ustrezajo pikam na levi sliki 4.



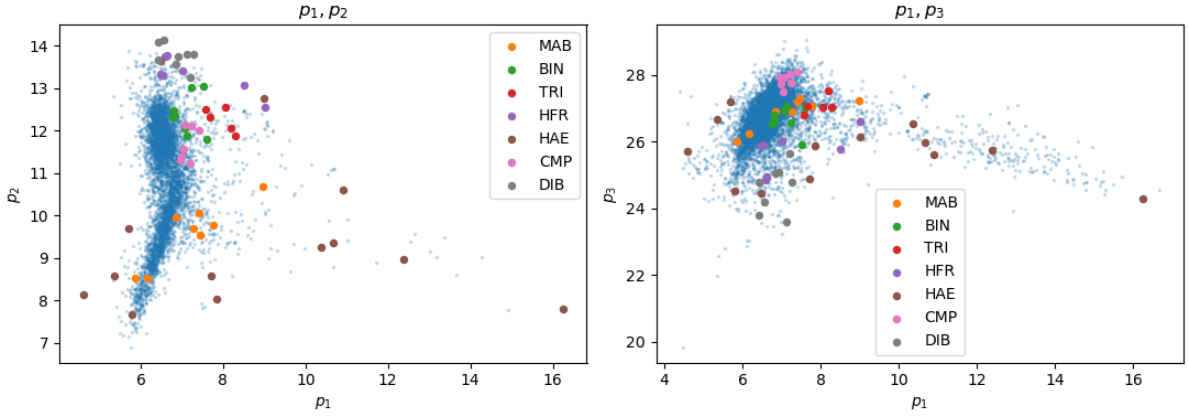
Slika 6: Skrajna spektra za parameter p_3. Levo spekter s p_3 =max, desno s p_3 =min, barvne so skladne z desno sliko 4.

Čisto informativno si lahko ogledamo še spektra iz sredine gruč s slike 4, ki ju v tem kontekstu lahko označimo za povprečna. Oba nakazujeta na obliko spektra binarnih zvezd.



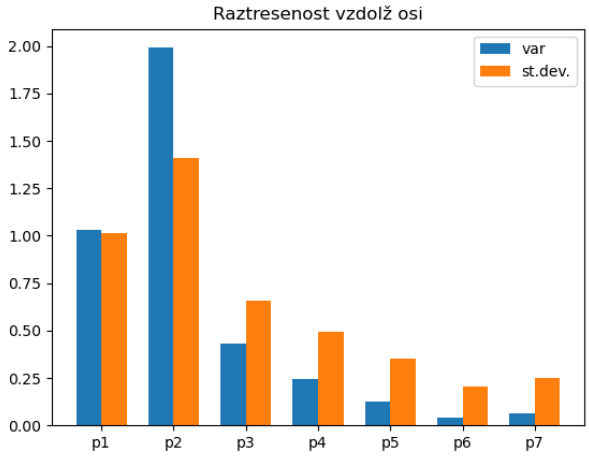
Slika 7: Spektra iz centra gruč za par p_1, p_2 (levo) ter p_1, p_3 (desno).

Na koncu sem v reducirane podatke umestil še učni set podatkov. Kot smo že videli, je rezultat bolj ali manj nerazčlenjen, na sliki 8 pa eksplicitno vidimo, da klasifikacija ne deluje dobro. Na desni sliki se zdi, kot da je ločen oblak, kjer se nahajajo samo HAE točke. Po drugi strani pa se HAE točke nahajo tudi drugot po centralni gruči, torej rezultat ni najbolj optimalen.



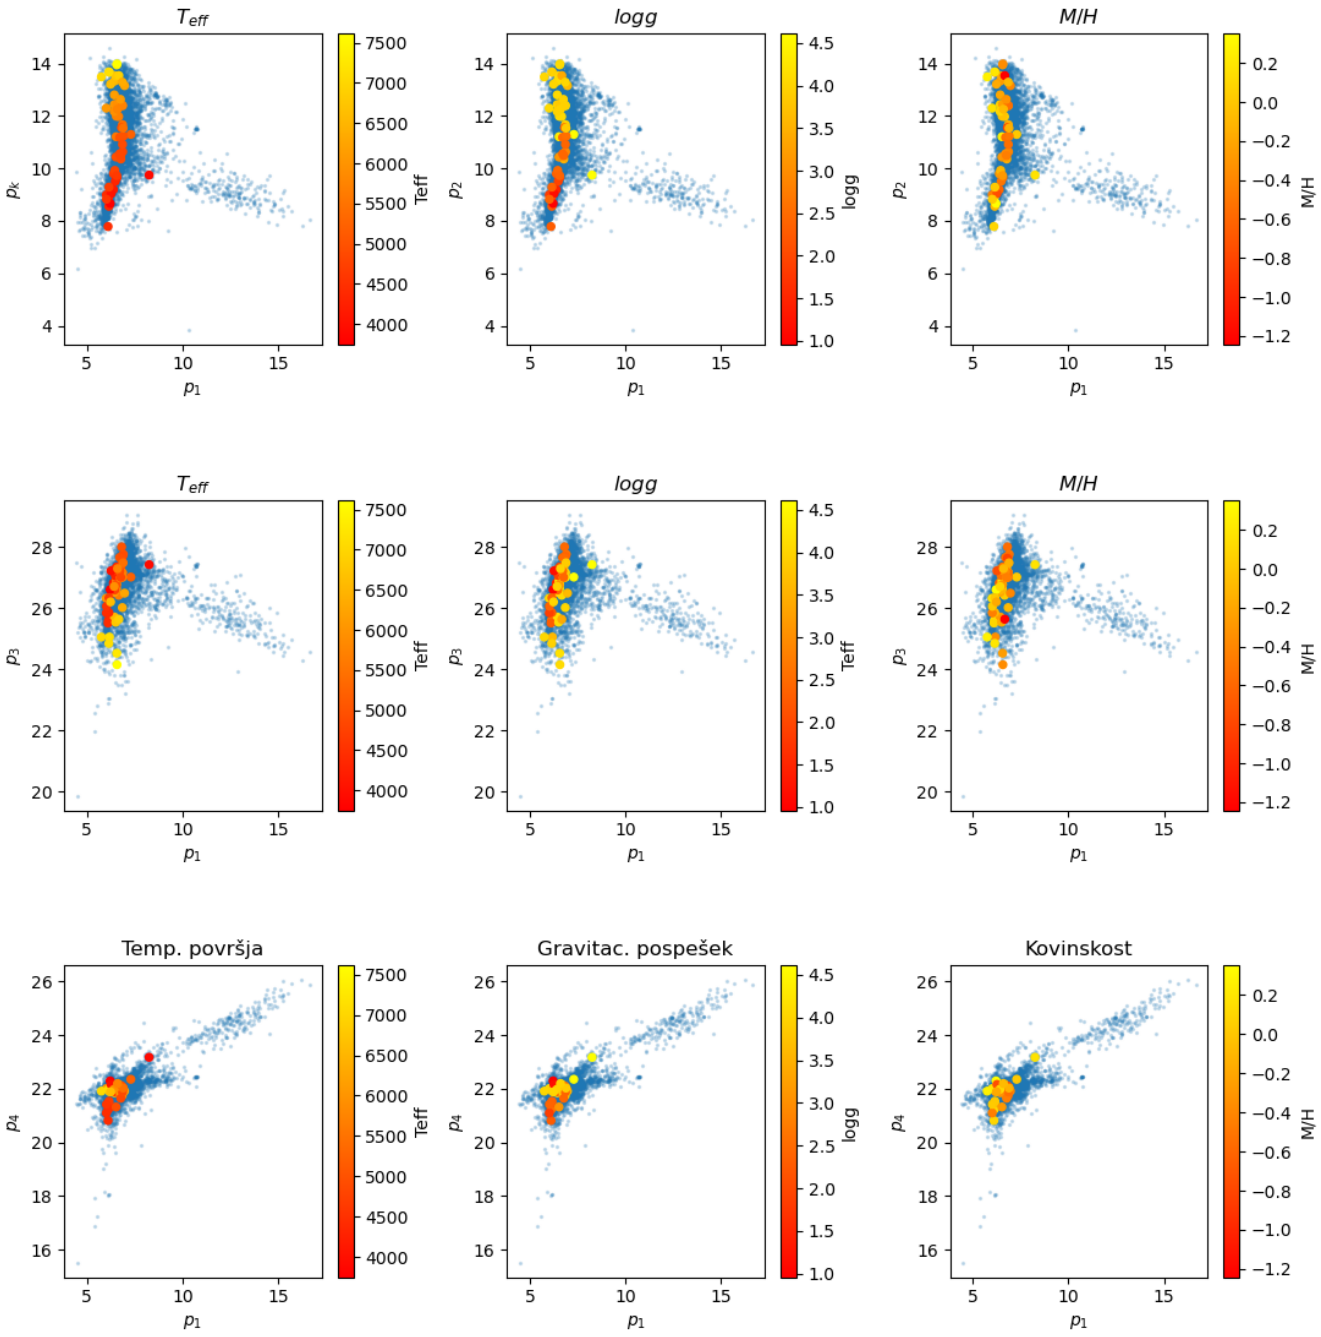
Slika 8: Redukcija PCA z učnim setom podatkov.

Pogledamo lahko še disperzije histogramov, ki jih dobimo s projekcijo na posamezne dimenzije. Kot smo videli že na oko, največji interval pripada koordinati p_2, s sledečimi pa strmo pada. V tem primeru je velika raztresenos zaželjena, zato nam lahko to tudi služi kot kriterij za kasnejšo izbiro komponent (npr. p_7 ima večji RMS kot p_6 in, če bomo potrebovali 6 projekcijskih dimenzij, bomo p_6 izpustili in uporabili p_7.)



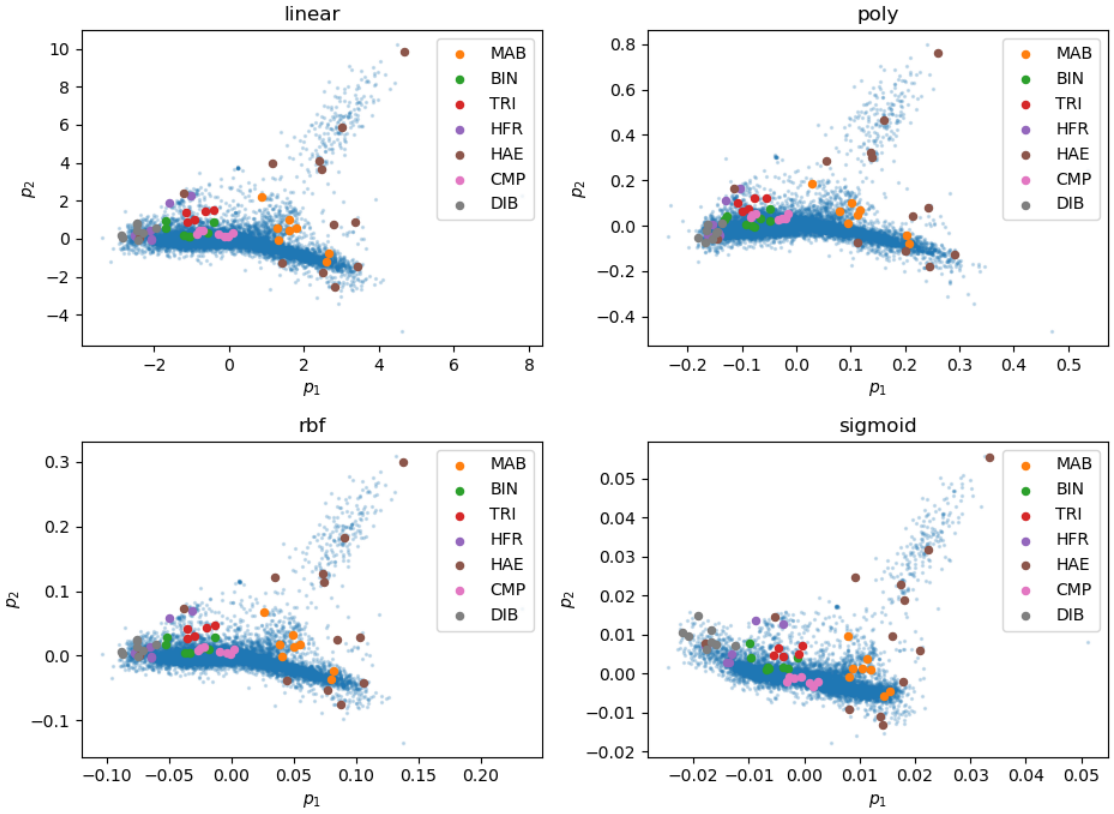
Slika 9: Raztresenost sprojiciranih točk po koordinatah projekcijskega prostora.

V datoteki `ucni_set_parameti.txt` se nahajajo tudi podatki o efektivni temperaturi površja, gravitacijskem pospešku na površju in kovinskosti v enotah $[M/H]$. Poglejmo kam v projekcijski prostor pade učni set in kaj lahko iz njega razberemo. Na sliki 10 so prikazane projekcije na prve 4 dimenzije z največjimi lastnimi vrednostmi. Izstopata gravitacijski pospešek in temperatura vzdolž osi p_2, kjer najdemo očiten naraščajoč trend teh dveh količin. Podoben vzorec opazimo tudi vzdolž p_3 vendar že nekoliko zastrt. Kovinskost in projekcije na preostale osi so brez jasnega vzorca.



Slika 10: PCA projakcija učnega seta.

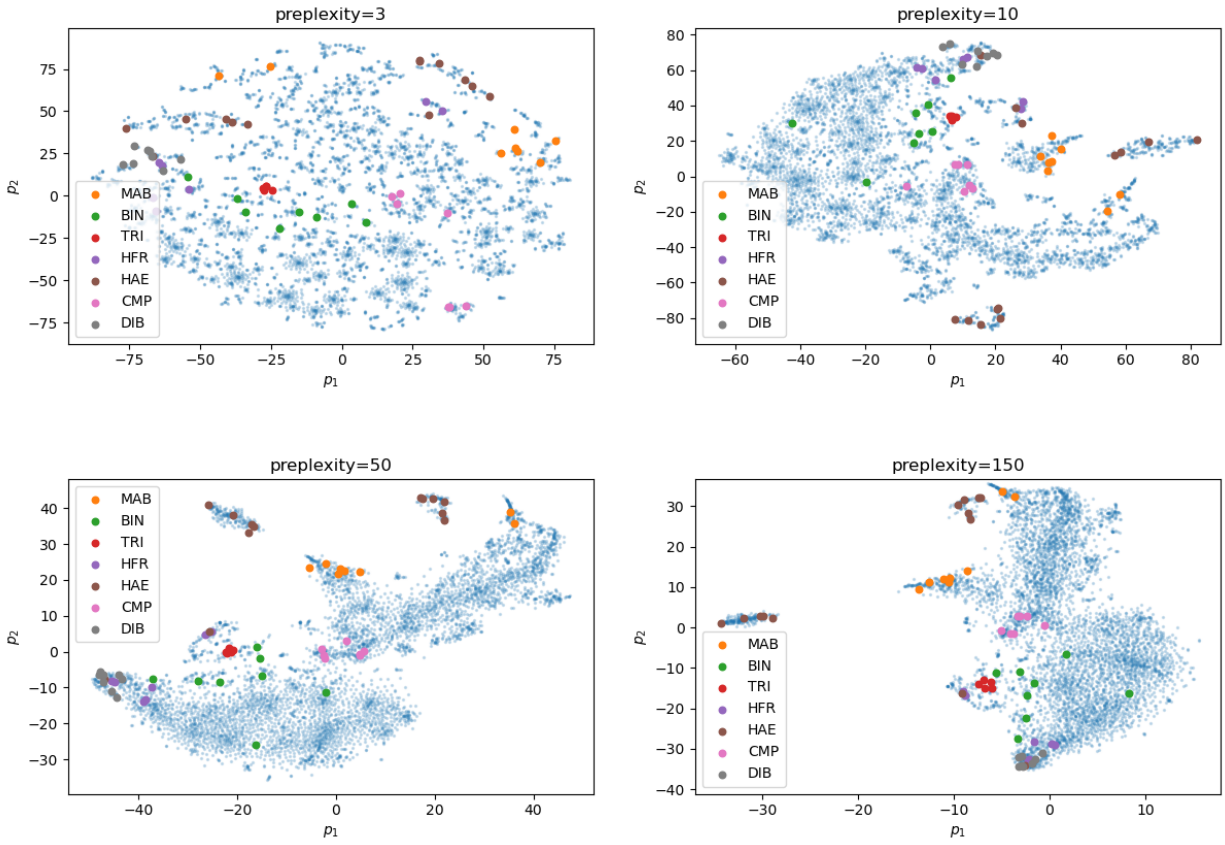
Slika 11 prikazuje natanko enako stvar, vendar z uporabo kernel PCA algoritma iz knjižnjice `sklearn`. Tukaj imamo na voljo različna jedra, vendar razlika med njimi ni bila znatna. Najbolje se je obneslo polinomsko jedro, kjer nekoliko bolj izstopa prej omenjen HAE oblak.



Slika 11: kernel PCA s polinomskim jedrom.

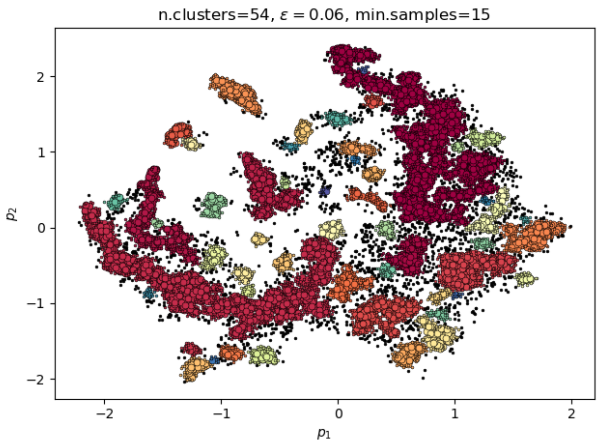
3 t-SNE

V tem delu sem uporabljal vgrajeno funkcijo iz knjižnjice `sklearn.manifold`. Vse projekcije so narejene na dve dimenziji, s hitrostjo učenja 100, Barnes-Hut aproksimacijo za zmanjšanje časovne zahtevnosti ter PCA začetno inicializacijo. Najprej si lahko ogledamo vpliv parametra *preplexity*, kar je prikazano na sliki 12. Velike vrednosti tega parametra vodijo k nastanku manjšega števila večjih gruč, v nasprotnem primeru pa k razdrobljeni strukturi manjših gruč. Iščemo torej optimalno vrednost, kjer točke ne bodo pomešane in kjer ne bodo v eni gruči.

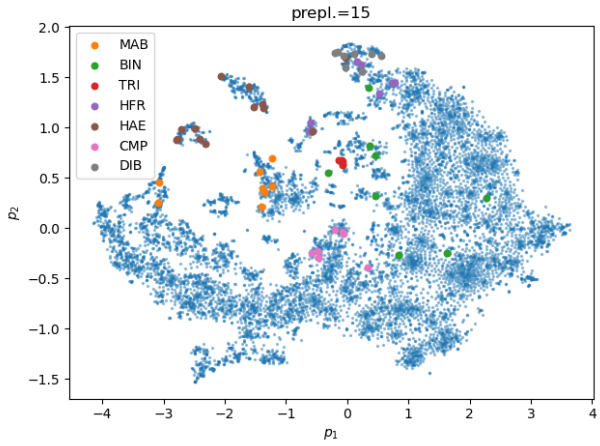


Slika 12: t-SNE redukcija dimenzij.

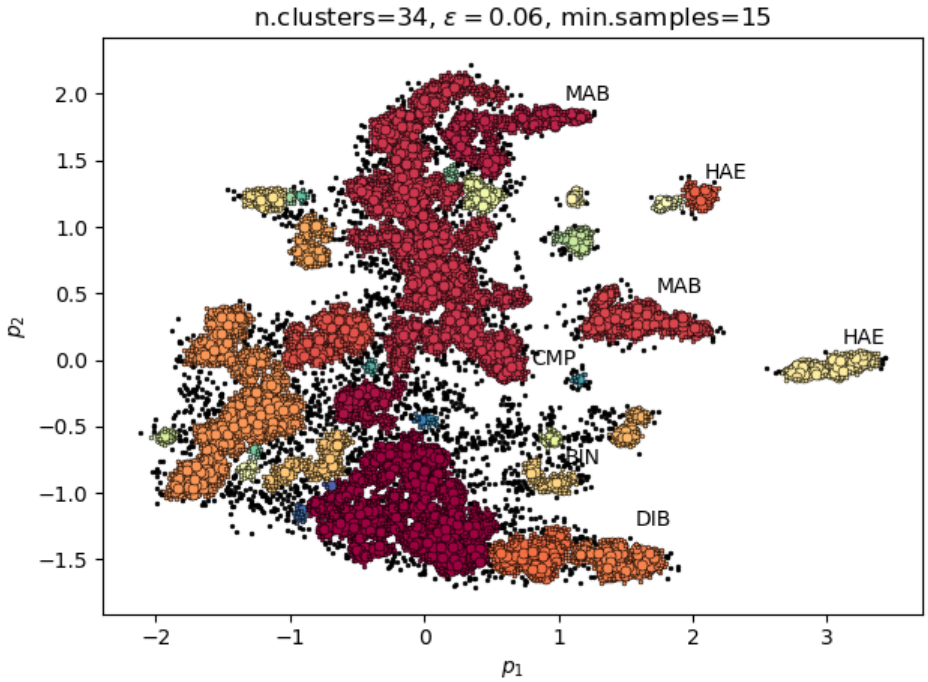
Slika 13 prikazuje osrednji rezultat, kjer so združeni znani tipi zvezd. Tukaj sem uporabil metodo `DBBSCAN`, kjer sem se poigral še z njenimi vhodnimi parametri. Glavni vpliv imata ε, ki določa največjo razdaljo med sosednjima točkama iz iste gruče in *min_samples*, ki je povezano s številom točk v guči. Skupaj določata tudi katere točke spadajo pod šum (na sliki črne pike). Najbolj smiselne rezultate sem dobil z $\varepsilon = 0.06$ in $min_samples = 15$. Na podlagi učnega seta tipov zvezd sem lahko za nekaj gruč določil katerim zvezdnim skupinam pripadajo.



(a) *preplexity* = 15, clustering.



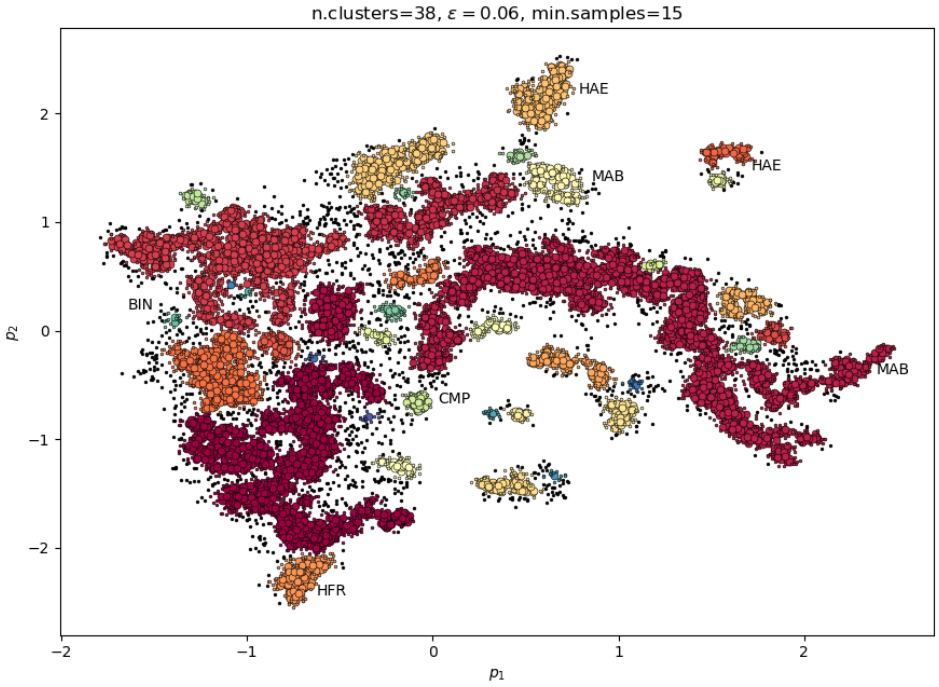
(b) *preplexity* = 15 + učni set.



(c) *preplexity* = 35, clustering.

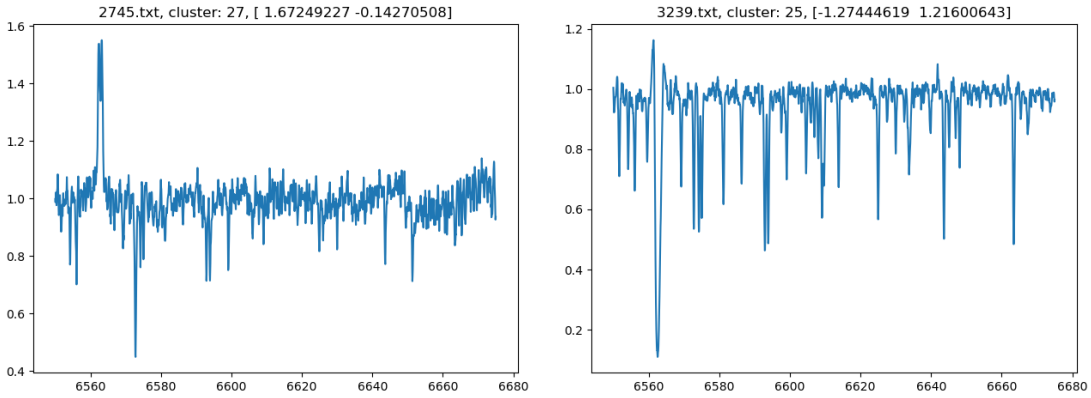
Slika 13: Clustering z metodo DBSCAN.

Na koncu sem si ogledal še klasifikacijo spektrov, ki jim porežemo območje okoli črte Hα. Spektrom sem odrezal del valovnih dolžin, ki so manjše od 6570Å. Rezultat je prikazan na sliki 14.



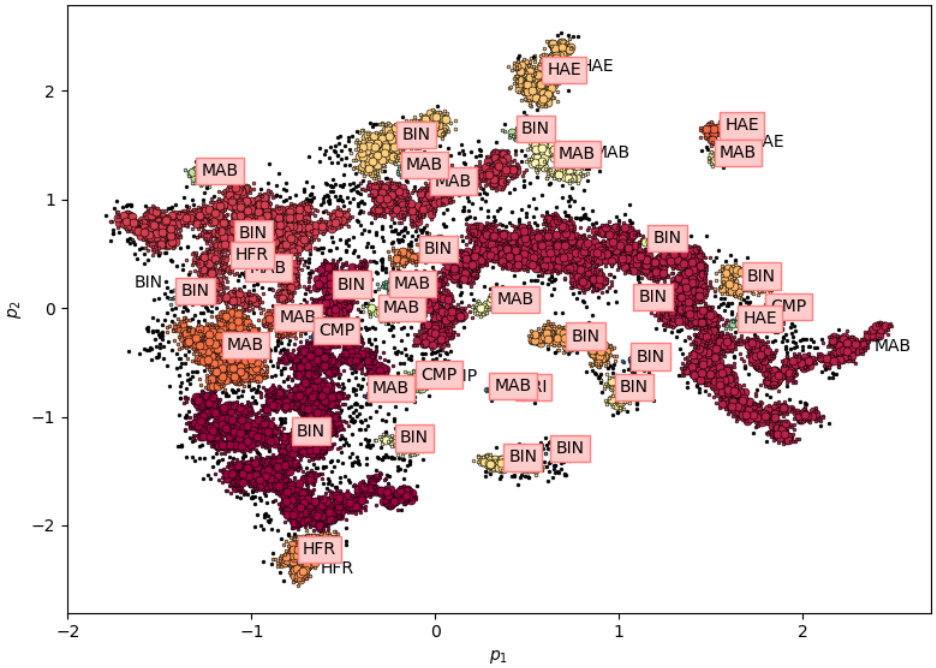
Slika 14: *preplexity* = 15, izvzet vodikov del.

Obstaja precej primerov, kjer nimamo reference za oznako, vseeno pa tvorijo dobro definirane gruče. Osredotočimo na sliko 14 in poglejmo reprezentativna spektra iz gruč obarvanih zeleno na skrajni desni, in levi zgoraj (slika 15). V prvem primeru je vodikova špica obrnjena navzgor, kar je značilno za HAE. Drug primer z ogromno tankimi špicami pripada skupini MAB.



Slika 15: Reprezentativni spektri iz gruč 1.

S pregledom vseh reprezentativnih spektrov lahko določimo povezavo še za preostale gruče. Končni rezultat je torej določitev tipa zvezd v gruči in je prikazan na sliki 16. V rdečih kvadratkih so navedene napovedi tipov gruč, kar lahko uporabimo v obratni smeri algoritma in vsakemu spektru določimo skupino kateri pripada. Rezultat klasifikacije vseh 10000 spektrov na podlagi spodnje slike je priložen v datoteki `spektri_oznake.txt`.



Slika 16: Avtomatsko določanje skupin.

4 Priloga: PCA koda

```
def odstej(A,B):
    a, b = len(A), len(A[0])

    C = np.zeros((a,b))
    for i in range(a):
        for j in range(b):
            C[i][j] = A[i][j] - B[i][j]

    return C

def obrni(A):
    n,m = len(A), len(A[0])
    B = np.zeros((n,m))
    for i in range(n):
        for j in range(m):
            B[i][j] = A[i][-1-j]

    return B

def redukcija(delez=0.90):
    summa = sum(D)
    g = 0
    for j in range(p):
        g += D[j]
```

```
        if g >= delez*summa: return j+1

    return j+1


# load wavelengths file
wav = np.loadtxt('spektri/val.dat', comments='#')

# load spectra in a loop
spectra_array=[]
for spectrum in range(1,10000):
    flux = np.loadtxt('spektri/%s.dat' % spectrum, comments='#')
    spectra_array.append(flux)

# create an array
X = np.array(spectra_array)

N = len(X)
p = len(X[0])

u = np.zeros(p)
for j in range(p):
    uu = 0
    for i in range(N):
        uu += X[i][0]

    u[j] = uu/N


h = np.ones(N)
B = odstej(X, np.outer(h,u))


# cov(B):
C =np.dot(np.transpose(B),B)/(N-1)


# Diagonalizacija:
D, V = np.linalg.eigh(C)
D = [D[-1-i] for i in range(p)]
V = obrni(V)


# Redukcija dimenzij:
l = redukcija(0.90)
print("l=",l)       # št. stolpcev

W = np.zeros((p,l))
for i in range(p):
    for j in range(l):
```

```
        W[i][j] = V[i][j]


# Projiciramo X na W:
T = np.dot(X,W)
```